

25.09.2026

Лекция 1. Задачи и проблематика

КЛ - компьютерная лингвистика

Задачи КЛ

Машинный перевод

Самые первые приложения КЛ. Простейшие модели выполняли пословный перевод. Сейчас для этого используется статистическая трансляция и нейронные сети.

Информационный поиск

Полнотекстовый поиск. Например, по ключевым словам или заголовкам страниц. Затем появилось индексирование документов. Для этого из слов получают леммы и считают сколько раз это слово встречается в документе.

Лемма - начальная форма слова, его основная часть.

Реферирование, аннотирование

Реферирование - извлечение наиболее важных сведений из текста и составление их краткого описания.

Вопросно-ответные системы

Вопросно-ответная система - система, являющаяся гибридом поисковых систем, которая использует естественно-языковой интерфейс.

- Система отбирает документы
- Реферировает их

- Синтезирует ответ

Смежные задачи

- Классификация текстов
- Кластеризация текстов
- Рубрицирование текстов

Классификация текстов

Сортировка текстовых документов по заранее определенным категориям.

Кластеризация текстов

Разбиение множества документов на подмножества (кластеры), параметры которых неизвестны.

Кластер - группа документов со схожими признаками.

Рубрицирование текстов

Отнесении порции информации к одной или нескольким категориям из ограниченного множества.

Прикладные задачи

Извлечение информации

Специфика задачи - распознавание и выявление в тексте определенной значимой информации:

- именованных сущностей
- отношений
- связанных с ними событий и фактов

Базовые подходы основаны на правилах и машинном обучении.

Редактура текстов

- Коррекция орфографии
- Автоматический перенос слов

Opinion Mining Sentiment Analysis

По сути это классификация текстов по эмоциональному отношению автора в объекту, событию и т.д.

Распознавание и синтез речи

Здесь работают гибридные подходы, а не только ML.

Проблематика

Разработка программ для автоматической обработки текстов на естественном языке (ЕЯ) - лингвистических процессоров.

Уровни

- Фонетический
- Морфологический
- Лексический (*этот уровень часто опускают*)
- Синтаксический
- Семантический
- Прагматическом (цель высказывания)

Сложность задач КЛ

- ЕЯ постоянно изменяется
- Есть множество способов сказать одно и то же

Лингвистические ресурсы

- Компьютерные словари
- Корпуса текстов
- Тезаурусы и онтологии

Компьютерные словари

Различаются охватом, представленной информацией

Корпуса текстов

Тексты собранные по определенному принципу вместе с разметкой (лексической, синтаксической).

Тезаурусы и онтологии

Тезаурус - семантический словарь (например, WordNet).

Онтология - формальное описание определенного набора понятий и сущностей.

Принципиальные отличия естественного языка

- Открытость и изменчивость
- Сочетаемость единиц ЕЯ на всех уровнях
- Большая системность (см. уровни ЕЯ)
- Степень асимметрии связи единиц и выражаемых ими смыслов

Омонимия является одной из основных проблем КЯ.