09.10.2026

Лекция 3. Лингвопроцессоры

Лингвопроцессор (ЛП) - система для обработки текстов на ЕЯ.

Используются для информационного поиска, машинного перевода, классификации т.д.

Обеспечения ЛП

- Лингвистическое
- Математико-алгоритмическое
- Программное

Типы анализа в ЛП

- Графематический
- Морфологический
- Синтаксический
- Семантический

1. Графематический

- Разделение входного текста на слова, знаки препинания и другие графемы
- Выделение предложений, абзацев, заголовков, примечаний
- Выделение устойчивых оборотов, не имеющих словоизменительных вариантов
- Выделение именованных сущностей
- Выделение специфических форматов (адреса, URL и т.п.)

Графематический дескриптор: Текст $\rightarrow$ Графематические теги

Есть дескрипторы текста.

2. Морфологический

Языки по морфологической структуре

- Изолирующие (морфемы максимально отделены друг от друга, азиатские языки). Нельзя тип корень и все такое выделить.
- Агглютинативные (морфемы семантически определены, но реально объединены в слова, татарский и финский напр.). Модно корень выделить, но куча всего еще дальше идет.
- Флективные (семантические и формальные границы между морфемами плохо различимы, русский и английский)

Преподаватель чуваш, бтв

Модели морфологии

- Элементно-комбинаторная модель
- Элементно-процессная модель (для флективных)
- Словесно-парадигматическая модель

Этапы морфологического анализа

1. Стеммирование - неточная вещь (быть, есть, будет)
2. Лемматизация - нормальная (словарная) форма языка - точная вещь
3. Приписывание граммем.
4. Получение парадигм.

   Для анализа флективных языков. Используются словарь основ, словарь парадигм.

Стем - краткая несловарная форма слова.

Граммема - может быть несколько (много падежей).

(Необязательно все этапы присутствуют)

Морфологические анализаторы

- Словарные - преобразование слова в лемму с помощью специальной таблицы

- Бессловарные

Автоматный морфоанализ

Правила:

1. следование морфем
2. следование алломорфов (ы-и вроде)

Конечные преобразователи

Конечный преобразователь (FST) - конечный автомат, который кроме распознавания входной последовательности формирует выходную последовательность.

3. Синтаксический анализ

Автоматическое построение функционального дерева фразы, т.е. нахождение взаимозависимостей между разноуровневыми элементами предложения.

Применение синтаксического анализа

- Снятие морфологической омонимии
- Проверка правописания
- Извлечение фактов и реферирование
- Генерация текстов
- Речевые технологии
- Создание банков деревьев

Деревья синтаксического анализа

- дерево непосредственных составляющих
- дерево зависимостей

Выбор дерева

- Проективность. Если ни одна из стрелок зависимостей не пересекает никакую другую стрелку или корневой узел (дерево

зависимостей)
- Наличие свободного порядка слов (дерево непосредственных составляющих)

Формальная грамматика

- Грамматика - описание способов построения предложений языка. Описание языка.
- Правило

Формальные модели грамматик

- Хомского - самая популярная
- CFPSG
- TG
- TAG
- и т.д.

> Восходящий синтаксический анализ работает быстро и хорошо.